

데이터 전처리 실습

결측치 확인, 자료형 변환, 조건별 데이터 추출, 카테고리별 집계를 학습합니다.

Chapter 2

이전

다음

1. 전처리란?

전처리는 분석하기 좋은 형태로 데이터를 정리하는 과정입니다. 잘못된 값, 비어 있는 값, 맞지 않는 자료형을 그대로 두면 분석 결과가 왜곡될 수 있습니다.

결측치

비어 있는 값을 확인하고 처리합니다.

자료형

문자와 숫자를 알맞게 변환합니다.

조건 추출

필요한 데이터만 선택합니다.

집계

그룹별 합계와 평균을 계산합니다.

2. 결측치 확인

```
import pandas as pd
```

```
df = pd.read_csv("sales.csv")
print(df.isna().sum())
```

`isna()` 는 비어 있는 값 여부를 확인하고, `sum()` 을 붙이면 컬럼별 결측치 개수를 볼 수 있습니다.

3. 결측치 처리

```
df_drop = df.dropna()
df["sales"] = df["sales"].fillna(0)
df["category"] = df["category"].fillna("unknown")
```

주의: 결측치를 무조건 삭제하면 데이터가 크게 줄어들 수 있습니다. 먼저 결측치가 왜 생겼는지 확인해야 합니다.

4. 자료형 변환

```
df["date"] = pd.to_datetime(df["date"])
df["sales"] = df["sales"].astype(int)
```

날짜는 날짜형으로, 금액은 숫자형으로 변환해야 정렬과 계산을 정확히 수행할 수 있습니다.

5. 조건별 데이터 추출

```
high_sales = df[df["sales"] >= 100000]
```

```
coffee_sales = df[df["category"] == "coffee"]
```

6. 카테고리별 집계

```
category_summary = df.groupby("category")["sales"].agg(["sum",  
"mean", "count"])  
print(category_summary)
```

`agg()` 를 사용하면 여러 통계값을 한 번에 계산할 수 있습니다.

7. 실습 체크리스트

- 결측치 개수를 확인할 수 있다.
- 결측치를 삭제하거나 대체할 수 있다.
- 자료형을 변환할 수 있다.
- 조건에 맞는 데이터를 추출할 수 있다.
- 카테고리별 합계, 평균, 건수를 계산할 수 있다.

8. 종합 실습 문제

1. 문제 출제

매출 데이터에서 결측치를 처리하고, 카테고리별 매출 요약표를 만드세요.

- `sales` 결측치는 0으로 대체합니다.
- `category` 결측치는 `unknown` 으로 대체합니다.

- `date` 컬럼은 날짜형으로 변환합니다.
- 카테고리별 총매출, 평균매출, 거래건수를 계산합니다.
- 결과를 `category_summary.csv` 로 저장합니다.

2. 개념 요약

개념	활용
<code>fillna</code>	결측치 대체
<code>to_datetime</code>	날짜형 변환
<code>groupby</code>	카테고리별 집계
<code>agg</code>	여러 통계 계산

3. 수도코드

```
CSV를 읽는다.  
결측치 개수를 확인한다.  
sales 결측치를 0으로 대체한다.  
category 결측치를 unknown으로 대체한다.  
date를 날짜형으로 변환한다.  
category 기준으로 sales의 합계, 평균, 건수를 계산한다.  
결과를 CSV로 저장한다.
```

4. 실행 예시

```
category    sum    mean  count  
coffee     350000  87500     4  
food        120000  60000     2  
unknown      0         0         1
```

← Chapter 2 목록

다음 학습 →