

모델 평가와 오버피팅

훈련 데이터와 테스트 데이터를 나누고, 오버피팅과 검증 데이터의 개념을 이해합니다.

Chapter 3

이전

다음

1. 왜 평가가 필요한가?

모델이 학습 데이터에서만 잘 맞는지, 새로운 데이터에서도 잘 맞는지 확인해야 합니다. 머신러닝의 목적은 외운 답을 재현하는 것이 아니라 새로운 데이터에 대해 잘 예측하는 것입니다.

훈련 데이터

모델을 학습시키는 데이터

테스트 데이터

학습 후 성능을 확인하는 데이터

검증 데이터

모델 선택과 조정에 사용하는 데이터

일반화

새 데이터에도 잘 작동하는 능력

2. 데이터 나누기

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
```

```
X, y, test_size=0.2, random_state=42
)
```

`test_size=0.2` 는 전체 데이터 중 20%를 테스트 데이터로 사용한다는 뜻입니다.

3. 오버피팅

오버피팅은 모델이 학습 데이터를 너무 자세히 외워서 새로운 데이터에는 약해지는 현상입니다.

상황	의미
훈련 성능 높음, 테스트 성능 낮음	오버피팅 가능성
훈련 성능 낮음, 테스트 성능 낮음	모델이 충분히 학습하지 못함
훈련 성능과 테스트 성능 모두 적절	일반화 가능성이 높음

4. 회귀 평가 지표

지표	의미
MSE	오차 제곱의 평균
RMSE	MSE의 제곱근, 실제 단위와 가까움
MAE	오차 절댓값의 평균
R^2	모델이 데이터를 얼마나 설명하는지 나타내는 값

5. 실습 체크리스트

- 훈련 데이터와 테스트 데이터를 구분할 수 있다.
- 오버피팅의 의미를 설명할 수 있다.
- `train_test_split()` 을 사용할 수 있다.
- 회귀 평가 지표의 의미를 설명할 수 있다.

6. 종합 실습 문제

1. 문제 출제

회귀 데이터를 훈련/테스트 데이터로 나누고, 선형 회귀 모델의 테스트 MSE를 계산하세요.

2. 개념 요약

개념	활용
<code>train_test_split</code>	데이터 분할
<code>fit</code>	훈련 데이터로 학습
<code>predict</code>	테스트 데이터 예측
MSE	테스트 오차 계산

3. 수도코드

```
입력 x와 목표 y를 준비한다.
훈련 데이터와 테스트 데이터로 나눈다.
회귀 모델을 만든다.
훈련 데이터로 모델을 학습한다.
```

테스트 데이터로 예측한다.
테스트 MSE를 계산한다.
훈련 성능과 테스트 성능 차이를 해석한다.

4. 실행 예시

훈련 MSE: 35.2
테스트 MSE: 58.7
해석: 테스트 오차가 훈련 오차보다 크지만 과도하게 크지는 않아 보입니다.

[← Chapter 3 목록](#)

[다음 학습 →](#)